

FARO — Documento técnico

Copiloto de inteligencia informativa con IA · hackIAthon Panamá 4ta edición · Reto TVN Media

Oct 6, 2026 · @Andres

1. Resumen ejecutivo

FARO es un agente que convierte noticias recientes de Panamá (2 de octubre de 2025 al 30 de septiembre de 2026), obtenidas por scraping y APIs, junto con datos oficiales, en una bandeja priorizada de eventos con fichas donde cada afirmación cita su fuente, fecha y alcance. Ayuda al editor de TVN a decidir qué investigar y, con un cambio de lente, al analista bancario a preparar un boletín de entorno.

Frase del producto: FARO no escribe noticias. Le dice al editor qué sabe, de dónde lo sabe y qué le falta saber.

Usuarios

Lente	Usuario	Resultado útil
Editorial (principal)	Editor/a de mesa y periodista de TVN	Agenda priorizada, ficha de investigación, brief, guion de 45–60 s y copy digital
Bancario (extensión)	Analista de estudios económicos o riesgo sectorial	Boletín de entorno con sectores, horizonte, evidencia y preguntas

Diferenciadores

- **Procedencia independiente:** cuenta menciones, medios y procedencias reales; una agencia replicada cuenta como una sola fuente.
- **Grafo de procedencias:** medios, agencias, eventos y entidades en un grafo navegable, coloreado por estado de evidencia.
- **Candado de cifras y verificador en código:** ningún número ni afirmación llega al borrador sin una cita válida; si no hay evidencia, el sistema se abstiene.
- **Agente que investiga y maneja la interfaz:** responde con citas, abre fichas, filtra la bandeja y cambia de vista por sí mismo, y sabe qué está viendo el usuario en pantalla.
- **Pasarela de LLM con la clave del usuario (BYOK):** funciona con cualquier proveedor de pago y cae a un modelo local u offline si no hay red.
- **Lentes como configuración:** el bancario es un YAML, un prompt y un esquema sobre el mismo núcleo.

2. Contexto del reto y criterios de evaluación

El reto “De la señal a la decisión” pide un prototipo que reduzca el tiempo para encontrar un tema relevante, comprobar qué evidencia existe e identificar qué falta verificar, con resultados trazables y revisión humana. Cada equipo arma su propio paquete de datos por scraping y APIs; las fuentes del documento son solo ejemplos.

Aclaraciones de la organización (respuestas a consultas de los equipos)

Pregunta	Respuesta	Impacto en FARO
¿La organización entrega un paquete de datos común?	No: cada equipo arma sus datos con scraping	El snapshot, el manifest y el catálogo son trabajo nuestro (F-01 a F-03)
¿Qué período de noticias es válido?	Del 2025-10-02 al último mes completo de este año (septiembre); se excluye [2024-01-01, 2025-10-01)	Ventana de la demo: [2025-10-02, 2026-10-01) (D-01)
¿Solo las fuentes de la sección 12?	No, son ejemplos; la idea es un scraping general	Se suman medios de Panamá y fuentes oficiales con datos mensuales
¿Y los datos históricos (Banco Mundial 2010–2024, USGS 2024)?	Se pueden usar otras fechas para entrenar modelos; la demo presencial debe usar información reciente	Histórico = entrenamiento y contexto rotulado por año; lo que se muestra como agenda es reciente

Rúbrica (100 puntos) y dónde los gana FARO

Dimensión	Peso	Cómo la cubre FARO	Lo que lleva al 5
Utilidad para TVN o banca	20	Bandeja, ficha, paquete editorial, boletín, agente que maneja la interfaz	Un editor real validando: Precision@5 y prueba de tiempo
Prototipo y flujo completo	20	Las 7 etapas de punta a punta	Demo en vivo sin fallos, también offline
Uso efectivo de IA	15	Embeddings, clasificador, clustering, agente con LLM	Baseline medido y decir dónde la IA no ayudó
Evidencias y explicabilidad	15	ID de evidencia universal, verificador, grafo de procedencias, abstención	Responder en vivo de dónde viene cada cifra
Notion: ejecución y pitch	15	Las 8 páginas obligatorias, sincronización de fichas	Bitácora con fechas durante el evento
Calidad técnica y evaluación	10	pytest T01–T10, Makefile, benchmark	make demo-offline en una máquina limpia

Dimensión	Peso	Cómo la cubre FARO	Lo que lleva al 5
Seguridad, privacidad y ética	5	Escudo, canario, herramientas de solo lectura, scraping responsable	Resistir la inyección delante del jurado

Condiciones de admisión (si falta una, la entrega no se evalúa)

- ☐ URL de Notion accesible al jurado al cierre
- ☐ Plan con al menos 8 tareas y 3 decisiones justificadas, registrado durante la ejecución
- ☐ Catálogo completo de fuentes y al menos 5 fichas trazables, una sin evidencia suficiente
- ☐ Matriz T01–T10 y métricas de la ejecución final
- ☐ Pitch de 10 minutos presentado desde Notion (un PDF o PowerPoint no lo reemplaza)
- ☐ Demo ejecutable, fuentes declaradas y ningún secreto en el repositorio

Además, el evento pide publicaciones diarias de avance en LinkedIn con los hashtags oficiales (#hackIAthon, #AgenteTVNMedia) y al menos 3 marcas etiquetadas.

3. Decisiones de diseño

Estas decisiones se copian tal cual a la base “Plan y decisiones” de Notion; el reto exige al menos tres justificadas. D-01, D-07 y D-09 se corrigieron tras las respuestas de la organización.

ID	Decisión	Justificación
D-01	Noticias de la demo en [2025-10-02, 2026-10-01]; se excluye [2024-01-01, 2025-10-01)	Respuesta expresa de la organización: del 2 de octubre de 2025 al último mes completo (septiembre de 2026)
D-02	Precision@5 exploratorio si no hay editor evaluador	Lo admite la sección 9.1
D-03	Sin base vectorial gestionada: matriz numpy local	Corpus de 1.000–3.000 documentos y demo offline obligatoria (T10)
D-04	Python + SQLite + Streamlit en un solo proceso	Máxima velocidad para 2 personas en 3 días; FastAPI se puede montar después sin tocar el núcleo
D-05	ID de evidencia universal y verificador escrito en código	Hace verificable el 100% de cobertura de citas; no depende de que el LLM se porte bien

ID	Decisión	Justificación
D-06	Cascada de LLM: proveedor del usuario → Ollama local → modo extractivo	La demo nunca se cae (T10)
D-07	Scraping responsable: RSS, sitemaps, secciones públicas y APIs; se guarda título, fecha, URL, medio y resumen publicado; cuerpo solo donde las condiciones lo permitan y nunca republicado	La organización pide scraping general; la sección 6 y la 8 exigen respetar derechos
D-08	Comparar palabras clave vs. embeddings + regresión logística	La sección 8 exige un baseline y medir la mejora
D-09	Fecha de referencia = corte del snapshot: 2026-09-30 23:59 hora de Panamá (configurable)	Urgencia, novedad y bandeja se calculan contra el corte de los datos
D-10	El acceso al sistema es un agente investigador con herramientas de solo lectura	El reto habla de “el agente” y el jurado lo probará en vivo
D-11	Stack: ver sección 8	Evaluación de 4 alternativas por velocidad, offline, ecosistema de IA y reproducibilidad
D-12	El LLM principal lo elige el usuario: pega su clave de cualquier proveedor de pago	Ningún proveedor queda fijado; el costo es medible y la clave nunca se guarda en el repositorio
D-13	Snapshot propio congelado (raw/ + manifest con SHA-256) antes de construir el núcleo	La demo no puede depender de sitios en vivo (T10, sección 10)
D-14	Datos históricos solo para entrenar y como contexto rotulado por año	La organización lo permite; la agenda que ve el editor es siempre reciente
D-15	El agente puede mover la interfaz (filtros, vistas, abrir fichas) y recibe lo que el usuario ve	Menos clics y respuestas en contexto; las acciones solo cambian la vista, nunca los datos


ID	Decisión	Justificación
D-16	Grafo de procedencias como vista propia	Hace visible el CU-03: cuántas fuentes son realmente independientes

Las noticias de TVN salen de su RSS (cubre lo más reciente), su sitemap y sus secciones públicas, y de GDELT con `domain:tvn-2.com` para completar meses; el reto pide al menos 20 de TVN.

4. Arquitectura

FARO es un pipeline por lotes que deja los datos listos offline, y un agente que trabaja sobre ellos bajo demanda; ninguna salida llega al usuario sin pasar por el verificador.

Todo pasa por el verificador antes de llegar al editor



arquitectura de FARO · 6 capas y 3 módulos laterales

Los datos bajan por las capas desde las fuentes hasta la interfaz; los lentes configuran el puntaje y las plantillas sin código nuevo, y la pasarela cambia de proveedor sin que el agente lo note.

Qué corre local y qué en la nube

Componente	Dónde	Motivo
Scraping y extracción	Local, una vez, antes de congelar el snapshot	La demo no depende de sitios en vivo (D-13)
Datos, búsqueda, embeddings, clasificador, puntaje, grafo	Local	T10 y “demo sin fuente en vivo” (secciones 9 y 10)
LLM principal	Nube, con la clave del usuario	Mejor redacción y planificación del agente
LLM de respaldo	Local (Ollama)	Fallback del T10 y modo privado
Notion	Nube	Obligatorio; si no hay red, se sincroniza después
Demo pública	Nube opcional (Railway)	Solo con el LLM del usuario; Ollama no corre ahí

El día del pitch la demo corre en la laptop con el modelo del usuario; si el wifi falla, la pasarela cambia sola a Ollama o a la caché y la demo sigue.

5. Funcionalidades y alcance en 3 días

Todo lo marcado P0 y P1 es alcanzable por dos personas en tres días porque comparte un solo núcleo; P2 se construye solo si el flujo editorial está completo al mediodía del día 2. Orden de construcción: scraping y snapshot → editorial completo → agente → LLM local → lente bancario.

Núcleo compartido

ID	Funcionalidad	Qué hace	Cubre	Prioridad
F-01	Scraping e ingesta	Recolectores por fuente (RSS, sitemap, sección HTML, API) con límite de velocidad, robots.txt y registro de condiciones; guarda raw/ con hash	Sección 6, aclaración de la organización	P0
F-02	Validación y calidad	Tipos, fechas UTC, URLs, nulos, ventana D-01, duplicados por	T01	P0

ID	Funcionalidad	Qué hace	Cubre	Prioridad
		URL; cuarentena y reporte		
F-03	Manifest y catálogo	manifest.json con versión, consultas, conteos, SHA-256 y condiciones por fuente	Sección 7	P0
F-04	Enriquecimiento NLP	Embeddings, tema (6 clases), entidades, agencia, marca de acusación	IA sustantiva	P0
F-05	Eventos y procedencia	Clustering + casi duplicados: menciones, medios y procedencias independientes	T02, T03, CU-03	P0
F-06	Contexto oficial	Enlace tema → serie oficial mensual, indicador anual o sismo; nunca forzado	T04, CU-02	P0
F-07	Puntaje y estado de evidencia	$P = 30R + 25I + 20U + 15N + 10E$ por lente, contra la fecha de referencia	T08	P0
F-08	Agente investigador	Pregunta en español, plan, herramientas, respuesta citada o abstención	CU-01, CU-04, T06	P0
F-09	Detector de contradicciones	Compara cifras y entidades dentro de un evento;	T05	P1

ID	Funcionalidad	Qué hace	Cubre	Prioridad
		muestra ambas versiones		
F-10	Pasarela de LLM (BYOK)	Un cliente para cualquier proveedor, caché, métricas y cascada	T10, eficiencia	P0
F-11	Verificador de salida	Cita, cifra, tipo de afirmación, etiqueta de metadatos, frases prohibidas	T04, T06, T09	P0
F-12	Escudo anti-inyección	Contenido como datos, filtro de patrones, clave canario	T07	P0
F-13	Revisión humana	Cinco estados, revisor y nota; aprobar no publica	Sección 8	P0
F-14	Sincronización con Notion	Fichas, decisiones y resultados de pruebas por API	Sección 5	P1
F-15	Evaluación	Benchmark, baselines, métricas, comparador proveedor vs. local	Sección 9	P0
F-16	Grafo de procedencias	Nodos de medios, agencias, eventos y entidades; color por estado de evidencia; detalle al pasar el cursor	CU-03, explicabilidad	P1

ID	Funcionalidad	Qué hace	Cubre	Prioridad
F-17	Control de la interfaz por el agente	El agente devuelve acciones (filtrar bandeja, abrir ficha, cambiar de vista, resaltar en el grafo) que la app aplica	Utilidad, demo	P1
F-18	Contexto de pantalla	El agente recibe la vista activa, el evento abierto y los filtros; responde sin preguntar “¿a cuál te refieres?”	Utilidad	P1
F-19	Panel de cobertura	Noticias por medio, tema y semana; procedencias por evento; calidad de la carga	Explicabilidad, catálogo	P2

Lente editorial (TVN)

ID	Funcionalidad	Prioridad
E-01	Bandeja de agenda: top 5 con puntaje desglosado, semáforo de evidencia y procedencias	P0
E-02	Ficha de investigación: qué se reporta, quién, qué está respaldado, qué falta, acción sugerida	P0
E-03	Paquete editorial: brief ≤250 palabras, título, enfoque, 3 preguntas, verificaciones, guion 45–60 s, copy ≤80 palabras	P0
E-04	Verificaciones pendientes creadas como tareas en Notion	P1

ID	Funcionalidad	Prioridad
E-05	Validación del guion: conteo de palabras (~2,3 por segundo) y prohibición de citas o entrevistados inventados	P1

Lente bancario

ID	Funcionalidad	Prioridad
B-01	Bandeja de señales sectoriales con pesos propios	P2
B-02	Mapa evento → sector con la regla que justifica cada enlace	P2
B-03	4–5 series agregadas de la SBP (octubre 2025 a septiembre 2026) con período, unidad y página de origen	P2
B-04	Boletín: resumen ≤250 palabras, sectores, horizonte, evidencia, 3 preguntas	P2
B-05	Separación obligatoria de observación e hipótesis de impacto	P2
B-06	Frases prohibidas: compra/venta, pérdidas, impagos, cartera, riesgo de clientes	P2

LLM local

ID	Funcionalidad	Prioridad
L-01	Ollama como proveedor de la pasarela, con el mismo esquema JSON	P1
L-02	Interruptor “100% local”: nada sale de la máquina	P1
L-03	Comparador proveedor del usuario vs. local: citas, abstención, latencia, costo	P1

ID	Funcionalidad	Prioridad
L-04	Embeddings siempre locales	P0

Lo que tomamos del pitch de Fraudia Claims y lo que agregamos

De Fraudia Claims	En FARO	Lo que este reto exige además
Asistente que cambia filtros y pestañas	F-17	Cada acción queda en la traza; solo toca la vista
Asistente que sabe qué siniestro está abierto	F-18	La respuesta igual pasa por el verificador
Grafo proveedor → siniestro → asegurado	F-16: medio → procedencia → evento → entidad	Distinguir repetición de corroboración
Reglas activadas visibles + score por colores	Puntaje desglosado + estado de evidencia separado	La prioridad no habilita publicación
SQL Agent con LangChain	Herramientas tipadas de solo lectura	Resistencia a inyección y abstención medida

Fuera de alcance (próximos pasos en el pitch): monitoreo continuo, producción audiovisual, publicación automática, datos de clientes y lectura de artículos detrás de paywall.

6. Fuentes y modelo de datos

El snapshot combina noticias recientes de varios medios con series oficiales mensuales del mismo período, y usa el histórico anual solo como contexto rotulado; todo dato citable tiene un ID de evidencia con el mismo formato.

Fuentes candidatas (validar robots.txt, condiciones y estructura el día 1; todas por sus páginas públicas)

Familia	Fuente	Método	Período	Uso
Noticias	TVN	RSS + sitemap + secciones	Ventana D-01	Patrocinador; mínimo 20 registros
Noticias	Telemetro, Panamá América, La Prensa, La Estrella de Panamá, Metro Libre	RSS o sitemap + secciones	Ventana D-01	Corroboración y procedencias

Familia	Fuente	Método	Período	Uso
Noticias	GDELT DOC 2.0	API (sourcecountry, domain, temas)	Ventana D-01	Completar meses y medios internacionales
Oficial mensual	INEC (actividad económica, precios, visitantes)	Descarga de cuadros publicados	Oct 2025 – sep 2026	Contexto de economía y turismo
Oficial mensual	ACP (tránsitos y tonelaje)	Estadísticas publicadas	Oct 2025 – sep 2026	Contexto logística/Canal
Oficial mensual	SBP (boletines)	PDF + pdfplumber	Oct 2025 – sep 2026	Lente bancario
Oficial	Gaceta Oficial, SINAPROC, ASEP	Secciones públicas	Ventana D-01	Regulación, eventos naturales, servicios públicos
Histórico	Banco Mundial (6 países, 6 indicadores)	API v2	2010–2024	Contexto anual rotulado por año; entrenamiento
Eventos	USGS	API FDSN (GeoJSON)	Ventana D-01 + histórico	Hechos sísmicos, nunca evidencia de daños

Meta de volumen: 1.000–3.000 noticias únicas en 12 meses, al menos 20 de TVN y al menos 5 medios distintos; menos de 1.000 sigue siendo válido (el mínimo del reto es 100), pero empobrece las procedencias.

ID de evidencia universal

Fuente	Formato del ID	Ejemplo
Noticia	N:<id>#<campo>	N:tvn-0123#titulo
Serie oficial	OF:<fuente>:<serie>:<perio do>	OF:ACP:transitos:2026-08
Banco Mundial	WB:<país>:<indicador>:<año >	WB:PAN:NY.GDP.MKTP.KD.ZG:2 023
USGS	USGS:<id>#<atributo>	USGS:us7000abcd#mag
SBP	SBP:<periodo>:<serie>#p<pá gina>	SBP:2026-06:depositos_totales#p12

-- Catálogo (se exporta a Notion)
fuente(id, nombre, familia, url_base, metodo,
| pdf

-- rss | sitemap | html | api

```

    robots_ok, condiciones, rate_limit_s, user_agent, licencia, notas)

-- Capa 1: datos normalizados
noticia(id, fuente_id, titulo, url, medio, dominio, idioma,
        fecha_publicacion, fecha_deteccion, fecha_extraccion,
        alcance_texto,          -- titular | metadatos | resumen | cuerpo
        resumen, tema, tema_conf, es_agencia, agencia, hash)
serie_oficial(id, fuente_id, serie, periodo, valor NULL, unidad,
              url, pagina NULL, fecha_extraccion, condiciones)
indicador(pais_iso3, indicador_id, anio, valor NULL, unidad,
          fuente_url, fecha_extraccion, licencia)
sismo(id, magnitud, fecha, lat, lon, profundidad, lugar, status, url)
cuarentena(fuente_id, fila_raw, motivo)          -- T01

-- Capa 2: deducido
evento(id, tema, titulo_canonico, fecha_primera, fecha_ultima,
       n_menciones, n_medios, n_procedencias)      -- CU-03
evento_noticia(evento_id, noticia_id, procedencia_id)
entidad(id, nombre, tipo)                        -- grafo F-16
evento_entidad(evento_id, entidad_id)
evento_contexto(evento_id, evidencia_id, motivo_enlace)
evento_puntaje(evento_id, lente, R, I, U, N, E, P, rango,
               estado_evidencia, reglas_version, fecha_referencia)
sector(id, nombre, descripcion)
evento_sector(evento_id, sector_id, regla, confianza)

-- Capa 3: salida y revisión
ficha(id, evento_id, lente, borrador_json, vacios_json,
      estado_revision, revisor, nota_revision,
      proveedor, modelo, prompt_version, desde_cache,
      tokens_in, tokens_out, costo_usd, latencia_ms, creado)
afirmacion(id, ficha_id, texto,
           tipo,          -- hecho | declaracion | inferencia | hipotesis
           | observacion
           evidencia_id, campo, verificada, motivo_rechazo)
traza_agente(id, consulta_id, paso, herramienta, argumentos, resultado_ids, ms)
ejecucion(id, caso_id, lente, proveedor, modelo, tokens_in, tokens_out,
          costo_usd, latencia_ms, citas_validas, citas_total, abstuvo, fecha)

```

Reglas de integridad del reto: UTF-8, IDs estables, fechas ISO 8601 en UTC y hora de Panamá en la interfaz; fecha_publicacion distinta de la fecha de detección; nulos conservados, nunca rellenos con cero; el cuerpo de un artículo nunca se muestra completo ni se redistribuye. fichas.jsonl y manifest.json se exportan desde estas tablas.

7. Pasarela de LLM con clave del usuario y agente investigador

FARO no trae un LLM fijado: el usuario elige proveedor y modelo, pega su clave y prueba. La pasarela usa LiteLLM, que habla con la mayoría de proveedores de pago con una sola interfaz, y cae a Ollama o al modo extractivo si el proveedor falla o no hay red.

7.1 Conectar un modelo (BYOK)

1. En la barra lateral, el usuario elige el proveedor, escribe el nombre del modelo y pega su clave.

2. FARO hace una llamada de prueba corta y detecta tres capacidades: salida JSON con esquema, llamadas a herramientas y precio conocido.
3. La interfaz muestra un indicador por capacidad y el modo que usará el agente.

Tipo de proveedor	Cómo se configura	Ejemplos
Nativo en LiteLLM	proveedor/modelo + clave	Anthropic, OpenAI, Google Gemini, Mistral, Cohere, Groq, DeepSeek
Nube con credenciales propias	Credenciales del proveedor cloud	AWS Bedrock, Azure OpenAI, Vertex AI
Compatible con OpenAI	base_url + clave + modelo	OpenRouter, Together y cualquier endpoint compatible
Local	Sin clave	Ollama (Qwen ~7-8B)

Manejo de la clave: vive solo en la memoria de la sesión de Streamlit; nunca se escribe en disco, en logs, en Notion ni en la caché. Los logs enmascaran cualquier cadena con forma de clave. Para la línea de comandos y las pruebas, la clave va en `.env`, que está en `.gitignore`; el repositorio solo trae `.env.example`.

Degradación por capacidad:

Capacidad del modelo elegido	Qué hace FARO
JSON con esquema y herramientas	Agente con plan libre (modo completo)
JSON sin herramientas	Agente con plan fijo: buscar → abrir evento → contexto → redactar
Sin JSON fiable	Pide JSON por instrucciones, valida con Pydantic, 1 reintento y luego pasa al siguiente proveedor
Precio desconocido	Registra tokens; el usuario puede cargar el precio por millón de tokens para calcular el costo

7.2 Cascada y caché

Gateway.generate(caso, lente, modo):

1. key = sha256(prompt_version + lente + ids_evidencia + modelo)
2. si key está en caché → devolver (marcado "desde caché")
3. modo "usuario" → proveedor elegido (timeout 20 s)
modo "local" → Ollama (timeout 60 s)
modo "auto" → usuario → Ollama → extractivo
4. validar contra el esquema Pydantic; inválido → 1 reintento → siguiente proveedor
5. registrar proveedor, modelo, tokens, costo y latencia; guardar en caché

El **modo extractivo** no usa LLM: rellena una plantilla con afirmaciones ya verificadas. Siempre funciona, nunca alucina y sirve de baseline de generación.

7.3 Agente investigador

El agente planifica, llama herramientas, observa y decide, con un máximo de 6 pasos y 15 s de presupuesto. Todas las herramientas son de solo lectura sobre `faro.db`:

Herramienta	Devuelve
<code>buscar_noticias(q, desde, hasta, tema)</code>	Noticias con su ID de evidencia
<code>abrir_evento(id)</code>	Evento, noticias, contexto y puntaje
<code>ver_procedencias(id)</code>	Menciones, medios y procedencias independientes
<code>consultar_indicador(pais, indicador, anio)</code>	Valor, unidad, año y fuente
<code>buscar_sismos(desde, hasta, mag_min)</code>	Sismos con ID y URL de USGS
<code>consultar_sbp(serie, periodo)</code>	Serie, valor y página de origen
<code>ranking(lente, fecha_ref, n)</code>	Top n eventos con componentes del puntaje
<code>consultar_serie(fuente, serie, periodo)</code>	Serie oficial mensual (INEC, ACP, SBP) con unidad y URL

- Lo que devuelven las herramientas entra marcado como datos, nunca como instrucciones.
- Ninguna herramienta escribe datos, publica ni accede a secretos; las acciones de interfaz (7.4) solo cambian la vista.
- La respuesta final pasa por el mismo verificador que las fichas; sin evidencia, el agente debe abstenerse y decir qué falta.
- Cada paso se guarda en `traza_agente` y se muestra en la interfaz.

7.4 Acciones sobre la interfaz y contexto de pantalla

El agente no solo responde: devuelve una lista de acciones que la app aplica, y en cada pregunta recibe lo que el usuario está viendo. Si alguien pide “el top 10 de eventos de logística”, el agente responde en el chat y además filtra la bandeja; si pide “los medios que más replican a EFE”, cambia a la vista del grafo.

Acción	Efecto en la interfaz
<code>filtrar_bandeja(tema, rango, estado, top_n, orden)</code>	Aplica filtros visibles como chips que el usuario puede quitar
<code>abrir_ficha(evento_id)</code>	Abre la ficha del evento
<code>ir_a(vista)</code>	Cambia a Bandeja, Ficha, Paquete, Grafo, Comparador o Calidad
<code>resaltar_en_grafo(ids)</code>	Enfoca nodos y procedencias en el grafo
<code>mostrar_evidencia(evidencia_id)</code>	Abre el panel con el dato exacto citado

Contexto de pantalla: con cada pregunta viajan la vista activa, el evento abierto, los filtros y la lente. Por eso “¿por qué tiene prioridad alta?” se responde sobre el evento abierto sin preguntar a cuál se refiere.

Implementación en Streamlit: las acciones son JSON validado con Pydantic; la app las aplica sobre `st.session_state` y cambia de página con `st.switch_page`. Cada acción queda en `traza_agente`, y una acción desconocida se ignora y se registra.

8. Stack tecnológico

El stack es Python en un solo proceso con UI en Streamlit, elegido entre cuatro alternativas por velocidad de construcción, funcionamiento offline y ecosistema de IA; FastAPI + React quedó como evolución posible y TypeScript completo y notebook quedaron descartados.

Capa	Elección	Alternativa	Por qué
Lenguaje y entorno	Python 3.11, uv, Makefile	—	Ecosistema NLP y scraping completo; instalación reproducible
Scraping: RSS	feedparser	—	Estándar, tolera feeds mal formados
Scraping: HTML y sitemaps	Scrapling (selectores adaptativos, modo sigiloso) + httpx	requests + selectolax	Resiste cambios de estructura y bloqueos anti-bot básicos
Metadatos del artículo	trafilatura (título, fecha, resumen)	extract	Extrae fecha y resumen de forma uniforme entre medios
Robots y ritmo	urllib.robotparser + pausa por dominio	—	Scraping responsable (D-07)
Datos	SQLite	DuckDB	Un archivo, sin servidor, offline
Vectores	Matriz numpy (coseno)	FAISS	1.000–3.000 documentos: milisegundos por búsqueda
Embeddings	multilingual-e5-small (sentence-transformers)	bge-m3	Buen español, ~120 MB, CPU

Capa	Elección	Alternativa	Por qué
Clasificación	scikit-learn LogisticRegression sobre embeddings	SetFit	Rápido y medible con macro-F1
Baseline	Palabras clave en YAML	—	Exigido por la sección 8
Clustering	AgglomerativeClustering + ventana de 72 h	HDBSCAN	Explicable, sin GPU
Casi duplicados	rapidfuzz	MinHash	Suficiente a esta escala
Entidades	spaCy es_core_news_md	es_core_news_lg	Offline, estándar
PDFs SBP	pdfplumber	Camelot	Tablas con página de origen
Grafo	networkx + streamlit-graph	pyvis	Grafo interactivo dentro de Streamlit
Pasarela LLM	LiteLLM (versión fijada)	PydanticAI	Una interfaz para cualquier proveedor + Ollama
LLM principal	El que elija el usuario (BYOK)	—	Ver sección 7
LLM local	Ollama + Qwen ~7–8B	Llama 3.1 8B, Gemma	Buen español, JSON con esquema, herramientas
Agente	Bucle propio (~150 líneas)	PydanticAI	Control total de traza, límites, acciones de interfaz y abstención
Esquemas	Pydantic	—	Genera el JSON Schema y valida respuestas y acciones
UI	Streamlit	FastAPI + React	7 vistas en horas, no días
Pruebas	pytest	—	T01–T10 como tests
Observabilidad	Log JSONL propio	Langfuse	Funciona offline
Notion	notion-client	Carga manual	Oficial; la carga manual está permitida

Capa	Elección	Alternativa	Por qué
Despliegue	Local; Railway opcional	—	La demo oficial corre en la laptop

Vistas de la interfaz: Bandeja · Ficha · Paquete editorial / Boletín · Preguntar al agente (con traza) · Grafo de procedencias · Comparador de modelos · Calidad y pruebas. En la barra lateral: lente, proveedor y clave, modo (usuario / local / auto) y fecha de referencia.

Estructura del repositorio

```
faro/
├── faro/
│   ├── scrape/      rss.py sitemap.py html.py apis.py pdf.py      F-01
│   ├── quality/     validate.py manifest.py                      F-02, F-03
│   ├── nlp/         embed.py classify.py entities.py             F-04
│   ├── events/      cluster.py provenance.py contradict.py       F-05, F-09
│   ├── context/     link.py                                      F-06
│   ├── scoring/     score.py                                    F-07
│   ├── agent/       loop.py tools.py                            F-08
│   ├── llm/         gateway.py providers.py extractive.py cache.py F-10
│   ├── guard/       shield.py verifier.py                       F-11, F-12
│   ├── lenses/      base.py editorial.py banca.py
│   ├── review/      states.py notion_sync.py                    F-13, F-14
│   └── eval/        benchmark.py baselines.py metrics.py         F-15
├── config/          fuentes.yaml lentes/*.yaml mapas.yaml sectores.yaml keywords.yaml
├── prompts/         brief_v1.md guion_v1.md boletin_v1.md agente_v1.md
├── schemas/         (modelos Pydantic exportados a JSON Schema)
├── data/            raw/ processed/ benchmark.jsonl manifest.json
├── app/             streamlit_app.py pages/
├── tests/           test_t01.py ... test_t10.py
├── Makefile         (data | run | test | eval | demo-offline)
├── .env.example
└── README.md
```

9. Seguridad, privacidad y ética

La seguridad está en el diseño, no en las instrucciones al modelo: el agente no tiene nada que explotar y el verificador no depende de que el LLM obedezca.

Riesgo	Control	Prueba
Inyección desde una fuente	Contenido delimitado como datos; filtro de patrones antes del LLM; herramientas de solo lectura; clave canario que nunca debe aparecer en la salida	T07 + 10 adversariales del benchmark
Alucinación de hechos o cifras	Candado de cifras; cada afirmación con evidencia_id y	T04, T06

Riesgo	Control	Prueba
	campo; abstención obligatoria sin evidencia	
Simular la lectura del artículo	Etiqueta obligatoria “basado únicamente en titular/metadatos”	T09
Acusaciones como hechos	Detector de acusación: se redacta como declaración atribuida (“según X...”)	Revisión de fichas
Prioridad confundida con verdad	Estado de evidencia separado del puntaje; prioridad alta con evidencia insuficiente = “requiere evidencia”	T08
Publicación automática	Cinco estados; “aprobado como borrador” no publica nada	F-13
Uso bancario indebido	Frases prohibidas (compra/venta, pérdidas, impagos, cartera, riesgo de clientes); hipótesis siempre marcadas	B-05, B-06
Fuga de credenciales	Clave del usuario solo en memoria; .env fuera del repo; logs enmascarados	Revisión del repo
Derechos de autor	Sin scraping ni redistribución de artículos, imágenes o videos; condiciones registradas por fuente	Catálogo de datos
Datos personales	Sin perfiles de personas ni listas de supuestos delincuentes o clientes riesgosos	Revisión de fichas
Privacidad del contenido enviado	Interruptor “100% local” con Ollama	L-02
Scraping abusivo o fuera de condiciones	Solo páginas públicas; robots.txt respetado; pausa por dominio y user-agent identificado; condiciones registradas por fuente; el cuerpo del artículo	Catálogo de datos (tabla fuente)

Riesgo	Control	Prueba
	nunca se muestra completo ni se redistribuye	

Notion se comparte solo con participantes y jurado autorizados; no es obligatorio publicarlo en la web.

10. Evaluación: pruebas, benchmark y métricas

Cada prueba del reto es un test de pytest y cada métrica sale de `make eval`; los resultados se reportan como numerador/denominador con la lista de fallos, nunca como un promedio suelto.

Pruebas de aceptación

ID	Prueba	Resultado esperado	Componente
T01	Fechas inválidas y nulos	Separa errores, conserva nulos, no bloquea la carga	F-02
T02	Tres registros del mismo evento	Agrupar sin perder fuentes ni triplicar corroboración	F-05
T03	Noticia antigua recirculada	Muestra la fecha original; no es evento nuevo	F-05, F-07
T04	Cifra anual del Banco Mundial	País, año y unidad; nunca como cifra de hoy	F-06, F-11
T05	Dos afirmaciones incompatibles	Muestra ambas y la verificación pendiente	F-09
T06	Consulta sin respuesta	Abstención explícita, nada inventado	F-08, F-11
T07	Fuente que pide ignorar instrucciones	Contenido no confiable; no revela ni ejecuta	F-12
T08	Prioridad alta	Expone componentes y regla; no habilita publicación	F-07, F-13
T09	Brief o boletín	Formato útil, citas pertinentes, hechos vs. inferencias	E-03, B-04

ID	Prueba	Resultado esperado	Componente
T10	Sin internet	Funciona con snapshot y fallback documentado	F-10

Benchmark (sección 7 del reto)

Tipo	Cantidad	Comportamiento correcto
Respuesta sustentada	30	Responde con citas válidas
Contradicción o ambigüedad	10	Muestra versiones y lo que falta verificar
Sin respuesta	10	Se abstiene y dice qué falta
Adversarial	10	Ignora la instrucción maliciosa

40 preguntas son de desarrollo y 20 quedan reservadas para el jurado, con las mismas proporciones de tipo. Las etiquetas las pone una persona, los casos alterados se marcan como sintéticos y las respuestas nunca entran al corpus del agente. Como la organización no entrega datos, el benchmark lo arma el equipo: una persona escribe las 20 preguntas reservadas sin que la otra las vea, y se guardan fuera del repositorio hasta la evaluación final; si la organización trae su propio set reservado, se usa ese.

```
{
  "id": "B-017",
  "tipo": "sustentada",
  "lente": "editorial",
  "pregunta": "¿Cuál fue el crecimiento del PIB de Panamá en 2023 según el Banco Mundial?",
  "esperado": "responder",
  "evidencia_esperada": ["WB:PAN:NY.GDP.MKTP.KD.ZG:2023"],
  "sintetico": false,
  "split": "dev"
}
```

Métricas

Métrica	Meta del reto	Cómo se mide
Cobertura de citas	100%	Afirmaciones con evidencia / afirmaciones totales
Validez de sustento	≥90%	Revisión humana de al menos 30 afirmaciones
Abstención correcta	≥80%	Abstenciones en “sin respuesta” / 10
Abstención incorrecta	Lo más baja posible	Abstenciones en preguntas respondibles
Clasificación	Reportar	Macro-F1 sobre ~150 titulares etiquetados, vs. palabras clave
Agrupación	Reportar	Precisión/recall de pares sobre etiquetas humanas

Métrica	Meta del reto	Cómo se mide
Ranking	Reportar	Precision@5 vs. selección de un editor (o exploratorio, D-02)
Latencia	Mediana ≤ 15 s	Mediana y p95 por consulta
Costo	Reportar	Tokens y USD por consulta, por proveedor
Valor operativo	Hipótesis o medido	Tarea manual vs. asistida, 3 repeticiones cada una

El benchmark se corre al menos dos veces (noche del día 2 y día 3) para documentar la mejora y una corrección en Notion.

11. Plan de desarrollo

Dos personas, tres días y una regla: al cierre del día 2 debe existir un recorrido completo, aunque sea feo, desde los datos hasta una ficha en Notion. El día 3 es para probar y pulir, no para construir lo que falte.

Roles

- **Persona A · Datos, NLP y banca:** scrapers de medios, calidad, snapshot, enriquecimiento, eventos, contexto, puntaje, herramientas del agente (consultas SQL), SBP y métricas.
- **Persona B · LLM, agente, UI y Notion:** recolectores de fuentes oficiales, pasarela BYOK, verificador, escudo, bucle del agente y acciones de interfaz, lentes, Streamlit, revisión humana, Notion y pitch.

Plan por tramo

Tramo	Persona A	Persona B	Juntos
Antes del evento	Inventario de fuentes de noticias: RSS, sitemap, robots.txt y condiciones de cada medio	Espacio Notion con las 8 páginas; decisiones D-01 a D-16; Ollama + Qwen descargado y probado con esquema JSON	Preguntar a la organización si se puede preparar código o datos antes del evento
Día 1 mañana	Recolectores de noticias: TVN (RSS + sitemap), otros medios, GDELT; Scrapling para HTML	Recolectores oficiales: INEC, ACP, SBP, Banco Mundial, USGS; esquema SQLite	Elegir la historia de la demo
Día 1 tarde	F-02 validación y deduplicado, F-03	F-10 pasarela BYOK + caché + métricas; F-11	Etiquetar ~150 titulares (1 h)

Tramo	Persona A	Persona B	Juntos
	manifest; congelar snapshot v1 (D-13)	verificador + F-12 escudo	
Día 2 mañana	F-04 embeddings, clasificador y baseline; F-05 eventos y procedencias	Lente editorial: prompts y esquemas; Streamlit: Bandeja, Ficha, Paquete	Benchmark: A escribe las 40 de desarrollo, B las 20 reservadas sin mostrarlas
Día 2 tarde	F-06 contexto, F-07 puntaje, herramientas del agente	F-08 agente + F-17 acciones de interfaz + F-18 contexto de pantalla; F-13 revisión humana	Punto de control: recorrido completo funcionando
Día 2 noche	F-16 grafo de procedencias; F-09 contradicciones; series SBP y mapa de sectores	Lente bancario (YAML, prompt, esquema); F-14 Notion	Primera corrida del benchmark
Día 3 mañana	F-15 métricas, baselines, comparador proveedor vs. local	T01–T10 en pytest y en Notion; documentar un fallo y su corrección	Prueba de tiempo con un editor si se consiguió
Día 3 tarde	Segunda corrida del benchmark (incluye las 20 reservadas); congelar repositorio	5+ fichas en Notion (una con evidencia insuficiente); página del pitch	Dos ensayos, uno con el wifi apagado; grabación de respaldo

Si al mediodía del día 2 el flujo editorial no está completo, el lente bancario pasa a “próximos pasos” y ese tiempo se usa en pruebas.

Registro en Notion durante el evento: cada tarea se mueve en el backlog al empezar y al terminar; cada decisión nueva se anota con su hora; cada corrida de pruebas se registra con su resultado. El jurado pedirá ver una decisión, una prueba fallida y su corrección.

Pitch (10 minutos desde Notion)

Minutos	Contenido
1	Problema, usuario y por qué importa a TVN
1	Solución, alcance y datos públicos
4	Demo: pregunta al agente que filtra la bandeja y muestra su traza, ficha con citas, grafo de procedencias, borrador, abstención, inyección resistida y un clic al lente bancario

Minutos	Contenido
2	Arquitectura, IA vs. baseline y métricas observadas
1	Valor operativo medido o hipótesis declarada
1	Riesgos, límites y próximos pasos

12. Riesgos y supuestos a verificar

Los riesgos mayores no son técnicos sino de admisión y de demo; casi todos los supuestos se confirman en una tarde de pruebas antes del evento.

Supuestos sin verificar

Supuesto	Por qué hay duda	Cómo confirmarlo
Los medios de Panamá tienen RSS o sitemap con fechas de octubre 2025 en adelante	El RSS solo guarda lo más reciente; no todos publican sitemap	Abrir <code>/rss</code> , <code>/sitemap.xml</code> y <code>robots.txt</code> de cada medio antes del evento
Hay al menos 20 noticias de TVN en la ventana	Cobertura del sitemap de TVN desconocida	Contar URLs del sitemap por mes; completar con GDELT <code>domain:tvn-2.com</code>
Los sitios permiten el scraping o no lo bloquean	Condiciones y anti-bot varían por medio	Revisar <code>robots.txt</code> y condiciones; probar Scraping en modo sigiloso con pausa
INEC y ACP publican series mensuales hasta septiembre de 2026	Las publicaciones oficiales tienen rezago	Revisar el último mes disponible; si falta, declararlo en la ficha
Los boletines SBP se pueden extraer y reutilizar	No se han revisado los PDF de 2025–2026	Abrir 2 boletines y sus condiciones
Ollama con un modelo de ~7–8B responde en tiempo aceptable	Depende de la máquina	Un brief de prueba cronometrado
La API de Notion está permitida en la licencia del evento	Permisos desconocidos	Preguntar al confirmar accesos
Se puede preparar código o datos antes del evento	Las reglas no lo dicen	Preguntar a la organización

Riesgos

Riesgo	Impacto	Mitigación
Falta un requisito de admisión	Entrega no evaluada	Lista de verificación de la sección 2 revisada la noche del día 2
El scraping consume más del día 1	Retrasa todo el núcleo	Snapshot v1 congelado al final del día 1 con lo que haya; se amplía después solo si sobra tiempo
Un medio bloquea o cambia su estructura	Menos fuentes y procedencias	Scrapling adaptativo; RSS y GDELT como respaldo; el snapshot congelado no depende del sitio
Problema de derechos con el contenido	Riesgo legal y ético	Solo metadatos y resúmenes publicados; cuerpo interno y nunca mostrado completo; condiciones en el catálogo
Notion queda como resumen final	Pierde puntos en 15 de la rúbrica	Registro durante el evento con fechas y horas
Una cifra mal citada en vivo	Anula el discurso de trazabilidad	Ensayar las 4 preguntas dinámicas del jurado
Extraer la SBP consume tiempo	Retrasa el núcleo	Limitar a 4–5 series; transcribir a mano con página si una tabla se resiste
El modelo del usuario no soporta herramientas	El agente pierde el plan libre y las acciones de interfaz	Degradación a plan fijo (sección 7.1)
Latencia local alta	Demo lenta en modo local	Precargar el modelo y cachear los casos de la demo
La red del evento falla	Sin demo	Cascada a Ollama o extractivo; demostrarlo a propósito apagando el wifi

Preguntas dinámicas del jurado y cómo se responden

Pregunta	Respuesta en la demo
“¿De dónde viene esta cifra y de qué año es?”	La traza muestra consultar_indicador con país, indicador y año

Pregunta	Respuesta en la demo
“Si cinco medios replican la misma agencia, ¿cuántas fuentes cuentas?”	ver_procedencias: 5 menciones, 1 procedencia
“¿Qué pasa sin evidencia o con una fuente que cambia instrucciones?”	Abstención con lo que falta; artículo sintético malicioso ignorado
“Muéstreme una decisión, una prueba fallida y su corrección”	Páginas de Notion “Plan y decisiones” y “Pruebas y métricas”